

รายงานโครงงาน
ระบบคัดกรองความเสี่ยงโรคหลอดเลือดสมอง
ด้วยการเรียนรู้ของเครื่อง
Stroke Risk Screening Using Machine Learning

จัดทำโดย

- | | |
|-----------------------|--------------------|
| 1. ชื่อ-นามสกุล | รหัสนักศึกษา |
| 2. ชื่อ-นามสกุล | รหัสนักศึกษา |
| 3. ชื่อ-นามสกุล | รหัสนักศึกษา |

เสนอ

อาจารย์

รายงานนี้เป็นส่วนหนึ่งของรายวิชา 344-362 การเรียนรู้ของเครื่อง (Machine Learning)
ภาคการศึกษาที่ ปีการศึกษา

สารบัญ

เรื่อง	หน้า
1. บทนำ (Introduction).....	1
1.1 ที่มาและความสำคัญของปัญหา.....	1
1.2 วัตถุประสงค์.....	1
1.3 ประเภทของปัญหาและขอบเขตของโครงการ.....	1
2. ชุดข้อมูล (Dataset).....	1
2.1 แหล่งที่มาและโครงสร้างของข้อมูล.....	1
2.2 ผลการสำรวจข้อมูลเบื้องต้น.....	2
3. วิธีการดำเนินงาน (Methodology).....	3
3.1 ภาพรวมขั้นตอนการดำเนินงาน.....	3
3.2 การเตรียมข้อมูล.....	4
3.3 การจัดการข้อมูลที่ไม่สมดุล.....	4
3.4 แบบจำลองที่ใช้ในการเปรียบเทียบ.....	4
3.5 การประเมินผลและการเลือกแบบจำลอง.....	5
3.6 การพัฒนาเว็บแอปพลิเคชัน.....	5
4. ผลการทดลอง (Experimental Results).....	5
4.1 ผลการจัดการข้อมูลที่ไม่สมดุล.....	5
4.2 ผลการเปรียบเทียบแบบจำลอง.....	5
4.3 การวิเคราะห์ Overfitting และการปรับค่าไฮเปอร์พารามิเตอร์.....	6
4.4 ผลการคัดเลือกคุณลักษณะ.....	6
4.5 ผลของแบบจำลองสุดท้าย.....	7
4.6 เหตุผลในการเลือกแบบจำลองสุดท้าย.....	7
4.7 ผลการพัฒนาเว็บแอปพลิเคชัน.....	8
5. อภิปรายผล (Discussion).....	8
5.1 จุดเด่นของแบบจำลอง.....	8
5.2 จุดอ่อนและข้อจำกัด.....	8
5.3 ปัญหาที่พบระหว่างการดำเนินงาน.....	8
5.4 แนวทางการพัฒนาในอนาคต.....	9
6. เอกสารอ้างอิง (References).....	9

1. บทนำ (Introduction)

1.1 ที่มาและความสำคัญของปัญหา

โรคหลอดเลือดสมอง (stroke) เป็นภาวะที่สมองขาดเลือดไปเลี้ยงเนื่องจากหลอดเลือดตีบ อุดตัน หรือแตก ส่งผลให้เซลล์สมองถูกทำลายอย่างรวดเร็ว และอาจนำไปสู่ภาวะอัมพฤกษ์ อัมพาต หรือการเสียชีวิต รายงาน Global Stroke Fact Sheet 2025 ขององค์การโรคหลอดเลือดสมองโลก (World Stroke Organization) ระบุว่าในแต่ละปีมีผู้ป่วยโรคหลอดเลือดสมองรายใหม่ทั่วโลกเกือบ **12 ล้านราย** และมีผู้เสียชีวิตมากกว่า **7 ล้านราย** ทั้งนี้ภาระโรคประมาณร้อยละ **84** มีสาเหตุมาจากปัจจัยเสี่ยงที่สามารถปรับเปลี่ยนได้ เช่น ความดันโลหิตสูงและการสูบบุหรี่ [1]

ด้วยเหตุนี้ การคัดกรองความเสี่ยงเบื้องต้นจากข้อมูลสุขภาพพื้นฐานจึงมีความสำคัญ เนื่องจากช่วยให้ผู้ที่มีความเสี่ยงสูงได้รับคำแนะนำให้พบแพทย์หรือปรับพฤติกรรมได้เร็วขึ้น โครงการนี้จึงประยุกต์ใช้การเรียนรู้ของเครื่อง (Machine Learning) เพื่อพัฒนาแบบจำลองสำหรับคัดกรองความเสี่ยงดังกล่าว พร้อมทั้งพัฒนาเว็บแอปพลิเคชันที่ผู้ใช้งานสามารถกรอกข้อมูลและรับผลการประเมินได้ทันที

1.2 วัตถุประสงค์

- 1) เพื่อพัฒนาแบบจำลองการเรียนรู้ของเครื่องด้วยไลบรารี scikit-learn สำหรับจำแนกความเสี่ยงต่อการเป็นโรคหลอดเลือดสมอง
- 2) เพื่อเปรียบเทียบประสิทธิภาพของแบบจำลองอย่างน้อยสองแบบจำลอง และคัดเลือกแบบจำลองที่เหมาะสมที่สุดโดยอาศัยตัวชี้วัดที่สอดคล้องกับลักษณะของปัญหา
- 3) เพื่อพัฒนาเว็บแอปพลิเคชันจำนวนหนึ่งหน้าที่สามารถรับข้อมูล ทำนายผล และแสดงความหมายของผลลัพธ์ได้จริง

1.3 ประเภทของปัญหาและขอบเขตของโครงการ

ปัญหานี้จัดเป็นการเรียนรู้แบบมีผู้สอน (Supervised Learning) ประเภท **การจำแนกแบบสองกลุ่ม (Binary Classification)** โดยตัวแปรเป้าหมายคือ stroke (1 หมายถึงเคยเป็นโรคหลอดเลือดสมอง และ 0 หมายถึงไม่เคยเป็น) ขอบเขตของโครงการครอบคลุมตั้งแต่การสำรวจข้อมูล การเตรียมข้อมูล การสร้างและเปรียบเทียบแบบจำลอง การประเมินผล จนถึงการพัฒนาเว็บแอปพลิเคชัน ทั้งนี้ ระบบที่พัฒนาขึ้นเป็น **เครื่องมือคัดกรองเพื่อการศึกษาเท่านั้น** มิใช่เครื่องมือวินิจฉัยทางการแพทย์ และไม่มีการใช้แบบจำลองจาก API ภายนอกในการทำนายผล

2. ชุดข้อมูล (Dataset)

2.1 แหล่งที่มาและโครงสร้างของข้อมูล

โครงการนี้ใช้ชุดข้อมูล **Stroke Prediction Dataset** ซึ่งเผยแพร่บนเว็บไซต์ Kaggle โดย fedesoriano [2] ประกอบด้วยข้อมูลจำนวน **5,110 รายการ** และ **12 คอลัมน์** ได้แก่ คุณลักษณะ (feature) จำนวน 10 รายการ รหัสผู้ป่วย (id) และตัวแปรเป้าหมาย (target)

คุณลักษณะของชุดข้อมูลแบ่งออกเป็นสามประเภท ดังนี้


- **คุณลักษณะเชิงตัวเลข** ได้แก่ age คืออายุ (ปี) มีค่าระหว่าง 0.08–82 ปี, avg_glucose_level คือระดับน้ำตาลในเลือดเฉลี่ย (mg/dL) และ bmi คือดัชนีมวลกาย (kg/m²) ซึ่งมีค่าสูญหาย 201 รายการ
- **คุณลักษณะทวิภาค** ได้แก่ hypertension คือภาวะความดันโลหิตสูง และ heart_disease คือโรคหัวใจ โดยกำหนดค่า 0 หมายถึงไม่เป็น และ 1 หมายถึงเป็น
- **คุณลักษณะเชิงกลุ่ม** ได้แก่ gender คือเพศ (Male, Female, Other), ever_married คือสถานะการเคยสมรส (Yes, No), work_type คือประเภทการทำงาน 5 ประเภท, Residence_type คือลักษณะที่อยู่อาศัย (Urban, Rural) และ smoking_status คือสถานะการสูบบุหรี่ 4 ระดับ ซึ่งรวมถึงค่า Unknown

ตัวแปรเป้าหมายคือ **stroke** ซึ่งมีค่า 1 จำนวน 249 ราย (ร้อยละ 4.87) และค่า 0 จำนวน 4,861 ราย ส่วนคอลัมน์ id เป็นรหัสผู้ป่วยซึ่งไม่ได้ใช้เป็นคุณลักษณะในการทำนาย

2.2 ผลการสำรวจข้อมูลเบื้องต้น

จากการสำรวจข้อมูลเบื้องต้น (Exploratory Data Analysis: EDA) พบประเด็นสำคัญซึ่งเป็นพื้นฐานในการกำหนดวิธีการเตรียมข้อมูล ดังนี้


- **ความไม่สมดุลของข้อมูล:** ผู้ป่วยโรคหลอดเลือดสมองมีเพียงร้อยละ 4.87 ของข้อมูลทั้งหมด (รูปที่ 1) แบบจำลองที่ทำนายว่าทุกรายไม่เป็นโรคจะได้ค่าความแม่นยำ (Accuracy) สูงถึงร้อยละ 95.1 แต่ไม่สามารถระบุผู้ป่วยได้เลย (Recall เท่ากับ 0) ดังนั้น Accuracy จึงไม่เหมาะสมที่จะใช้เป็นตัวชี้วัดหลัก



รูปที่ 1 การกระจายตัวของตัวแปรเป้าหมาย

- **ค่าสูญหายที่ไม่ได้เกิดขึ้นแบบสุ่ม:** คอลัมน์ bmi มีค่าสูญหาย 201 รายการ (ร้อยละ 3.9) โดยกลุ่มที่มีค่าสูญหายมีอัตราการเป็นโรคร้อยละ **19.9** เทียบกับร้อยละ 4.3 ในกลุ่มที่มีค่าครบถ้วน และมีผู้ป่วยอยู่ 40 จาก 249 ราย การลบรายการเหล่านี้จึงทำให้สูญเสียข้อมูลของกลุ่มผู้ป่วยซึ่งมีจำนวนน้อยอยู่แล้ว
- **ค่าสูญหายแฝง:** smoking_status มีค่า Unknown จำนวน 1,544 รายการ (ร้อยละ 30.2) ซึ่ง 618 รายการเป็นกลุ่มเด็ก และ gender มีค่า Other เพียง 1 รายการ ทั้งนี้ ไม่พบข้อมูลซ้ำซ้อน

- **ค่าผิดปกติ (Outlier):** ตามเกณฑ์ IQR คอลัมน์ avg_glucose_level มีค่าผิดปกติ 627 รายการ แต่กลุ่มดังกล่าวมีอัตราการเป็นโรคร้อยละ 13.4 จึงถือเป็นสัญญาณที่มีความหมาย ส่วน bmi มีค่าสูงผิดปกติถึง 97.6
- **ปัจจัยที่สัมพันธ์กับโรค (รูปที่ 2):** อัตราการเป็นโรคเพิ่มขึ้นจากร้อยละ 0.2 ในกลุ่มอายุ 0-19 ปี เป็นร้อยละ 17.7 ในกลุ่มอายุ 70 ปีขึ้นไป ผู้ที่เป็นโรคหัวใจและผู้ที่มีความดันโลหิตสูงมีอัตราร้อยละ 17.0 และ 13.3 ตามลำดับ ส่วน ever_married และ work_type มีความสัมพันธ์กับโรคผ่านตัวแปรอายุ (ตัวแปรกวน) ขณะที่ gender และ Residence_type มีความแตกต่างเพียงเล็กน้อย



รูปที่ 2 อัตราการเป็นโรคหลอดเลือดสมองจำแนกตามกลุ่ม (เส้นประแสดงค่าเฉลี่ยรวมร้อยละ 4.9)

3. วิธีการดำเนินงาน (Methodology)

3.1 ภาพรวมขั้นตอนการดำเนินงาน

การดำเนินงานทั้งหมดพัฒนาด้วยภาษา Python โดยใช้ scikit-learn [3] เป็นไลบรารีหลัก ขั้นตอนการเตรียมข้อมูลและแบบจำลองถูกรวมไว้ใน **Pipeline** เดียวกันเพื่อให้ขั้นตอนที่ต้องเรียนรู้ค่าทางสถิติจากข้อมูล (เช่น ค่ามัธยฐาน ค่าเฉลี่ย และส่วนเบี่ยงเบนมาตรฐาน) คำนวณจากชุดข้อมูลฝึก (Train) เท่านั้น อันเป็นการป้องกันปัญหาการรั่วไหลของข้อมูล (data leakage) ขั้นตอนโดยรวมประกอบด้วย

- 4) การสำรวจข้อมูลและกำหนดแนวทางการเตรียมข้อมูล
- 5) การแบ่งข้อมูลเป็นชุดฝึกร้อยละ 80 และชุดทดสอบร้อยละ 20 แบบ stratified
- 6) การเตรียมข้อมูลและการจัดการข้อมูลที่ไม่สมดุล
- 7) การสร้างและเปรียบเทียบแบบจำลอง การปรับค่าไฮเปอร์พารามิเตอร์ และการคัดเลือกคุณลักษณะด้วย Cross-Validation
- 8) การกำหนดค่าเกณฑ์ตัดสินใจ (threshold) และประเมินผลแบบจำลองสุดท้ายด้วยชุดทดสอบเพียงครั้งเดียว
- 9) การบันทึกแบบจำลองและพัฒนาเว็บแอปพลิเคชัน

3.2 การเตรียมข้อมูล

การเตรียมข้อมูลดำเนินการตามผลการสำรวจข้อมูล โดยมีขั้นตอนและเหตุผลประกอบ ดังนี้

- **การทำความสะอาดข้อมูล:** ตัดคอลัมน์ id เนื่องจากไม่มีความหมายต่อการทำนาย และตัดรายการที่ gender มีค่า Other ซึ่งมีเพียง 1 รายการ ไม่เพียงพอต่อการเรียนรู้
- **การตรวจสอบข้อมูลซ้ำซ้อน (Duplicate):** ตรวจสอบทั้งแบบรวมและไม่รวม คอลัมน์ id ผลการตรวจสอบไม่พบข้อมูลซ้ำซ้อน
- **การแบ่งข้อมูล (Train/Test Split):** แบ่งเป็นชุดฝึกร้อยละ 80 และชุดทดสอบร้อยละ 20 โดยกำหนด stratify = y และ random_state = 42 เพื่อรักษาสัดส่วนผู้ป่วยให้เท่ากันทั้งสองชุดและให้ผลลัพธ์ทำซ้ำได้
- **การจัดการค่าสูญหาย (Missing Value):** เติมค่า bmi ที่สูญหายด้วยค่ามัธยฐานผ่าน SimpleImputer และกำหนด add_indicator = True เนื่องจากค่ามัธยฐานทนต่อค่าผิดปกติ และการสูญหายของค่า bmi เป็นสัญญาณที่มีความหมาย จึงเก็บไว้เป็นคุณลักษณะเพิ่มเติม
- **การจัดการค่า Unknown:** กำหนดค่า Unknown ของ smoking_status เป็นกลุ่มหนึ่งแยกต่างหาก เนื่องจากมีสัดส่วนสูงถึงร้อยละ 30 และส่วนใหญ่เป็นกลุ่มเด็ก
- **การปรับสเกล (Scaling):** ใช้ StandardScaler กับข้อมูลเชิงตัวเลข เพื่อให้คุณลักษณะมีสเกลเท่ากัน ซึ่งจำเป็นสำหรับ Logistic Regression
- **การเข้ารหัส (Encoding):** ใช้ OneHotEncoder กับข้อมูลเชิงกลุ่ม เนื่องจากข้อมูลไม่มีลำดับ จึงไม่ใช่ Label Encoding
- **การคัดเลือกคุณลักษณะ (Feature Selection):** เปรียบเทียบชุดคุณลักษณะด้วย 5-fold Cross-Validation เพื่อทดสอบสมมติฐานจากผลการสำรวจข้อมูล

3.3 การจัดการข้อมูลที่ไม่สมดุล

เนื่องจากข้อมูลมีความไม่สมดุลสูง จึงเปรียบเทียบสามวิธี ได้แก่ (1) การกำหนดน้ำหนักคลาส (class weight = "balanced") ซึ่งเพิ่มค่าปรับเมื่อทำนายกลุ่มผู้ป่วยผิดพลาด (2) SMOTE [4] ซึ่งสังเคราะห์ตัวอย่างของกลุ่มผู้ป่วยเพิ่มเติม และ (3) Random Undersampling ซึ่งสุ่มลดตัวอย่างของกลุ่มที่ไม่เป็นโรค สำหรับวิธีที่ 2 และ 3 ใช้ Pipeline ของไลบรารี imbalanced-learn [5] เพื่อให้การสร้างหรือลดตัวอย่างกระทำเฉพาะกับชุดข้อมูลฝึก

3.4 แบบจำลองที่ใช้ในการเปรียบเทียบ

โครงการนี้เปรียบเทียบแบบจำลองจำนวน 3 แบบจำลอง ได้แก่ (1) **Logistic Regression** ซึ่งเป็นแบบจำลองเชิงเส้นที่ให้ค่าความน่าจะเป็นและอธิบายผลได้ด้วยค่าสัมประสิทธิ์ (2) **Decision Tree** (max_depth = 5) ซึ่งจำแนกข้อมูลด้วยกฎแบบลำดับขั้น และรองรับความสัมพันธ์ที่ไม่เป็นเชิงเส้น และ (3) **Random Forest** (300 ต้น, max_depth = 8, min_samples_leaf = 5) ซึ่งรวมผลจากต้นไม้หลายต้น (bagging) เพื่อลดความแปรปรวน ทุกแบบจำลองใช้ class_weight ในการจัดการข้อมูลที่ไม่สมดุล และใช้ DummyClassifier ที่ทำนายคลาสที่พบบ่อยที่สุดเป็นแบบจำลองฐาน (baseline)

3.5 การประเมินผลและการเลือกแบบจำลอง

- **ตัวชี้วัด:** Accuracy, Precision, Recall, F1-score, Confusion Matrix, ROC-AUC และ PR-AUC ซึ่งเหมาะสมกับข้อมูลที่ไม่สมดุล [6] โดยกำหนดให้ **Recall ของกลุ่มผู้ป่วย** เป็นตัวชี้วัดหลัก เนื่องจากในงานคัดกรอง การไม่พบผู้ป่วยที่เป็นโรคจริง (False Negative) ก่อให้เกิดความเสียหายมากกว่าการแจ้งเตือนเกินจริง (False Positive)
- **Stratified 5-Fold Cross-Validation:** ใช้บนชุดข้อมูลฝึกเพื่อเปรียบเทียบแบบจำลองอย่างน่าเชื่อถือ และใช้ **GridSearchCV** (ตัวชี้วัด PR-AUC) ในการปรับค่าไฮเปอร์พารามิเตอร์
- **ค่าเกณฑ์ตัดสินใจ:** เลือกจากค่าความน่าจะเป็นแบบ out-of-fold ของชุดข้อมูลฝึก โดยกำหนดให้ Recall ไม่ต่ำกว่า 0.80 และใช้ชุดทดสอบเพียงครั้งเดียวเพื่อรายงานผลสุดท้าย

3.6 การพัฒนาเว็บแอปพลิเคชัน

แบบจำลองสุดท้ายซึ่งประกอบด้วย Pipeline และค่าเกณฑ์ตัดสินใจถูกบันทึกด้วย joblib จากนั้นพัฒนาส่วนประมวลผลด้วย **Flask** [7] ซึ่งให้บริการ API /predict สำหรับรับข้อมูลรูปแบบ JSON ตรวจสอบความถูกต้องของค่าที่รับเข้า และส่งคืนคะแนนความเสี่ยง ส่วนหน้าเว็บพัฒนาด้วย HTML, CSS และ JavaScript ประกอบด้วยช่องกรอกข้อมูลปุ่ม Predict ส่วนแสดงผลการทำนาย และคำอธิบายความหมายของผลลัพธ์

4. ผลการทดลอง (Experimental Results)

4.1 ผลการจัดการข้อมูลที่ไม่สมดุล

ผลบนชุดทดสอบ (threshold = 0.5) พบว่าแบบจำลองฐานซึ่งทำนายว่าทุกรายไม่เป็นโรคได้ค่า Accuracy 0.951 แต่ Recall เท่ากับ 0 ส่วน Logistic Regression ที่ไม่ได้จัดการความไม่สมดุลได้ค่า Accuracy 0.951 เช่นกัน แต่ระบุผู้ป่วยได้เพียง 1 จาก 50 ราย (Recall 0.02, F1 0.039)

เมื่อจัดการความไม่สมดุลด้วยวิธีต่าง ๆ ค่า Recall เพิ่มขึ้นอย่างชัดเจน โดยวิธี **class_weight** ได้ค่า Recall 0.80, Precision 0.142, F1 0.242 และ PR-AUC 0.225 วิธี **SMOTE** ได้ค่า Recall 0.76, Precision 0.136, F1 0.231 และ PR-AUC 0.241 และวิธี **Undersampling** ได้ค่า Recall 0.82, Precision 0.129, F1 0.222 และ PR-AUC 0.213 จะเห็นได้ว่าการเพิ่มขึ้นของ Recall แลกมาด้วย Precision ที่ลดลง (trade-off) ซึ่งหลีกเลี่ยงไม่ได้ ทั้งนี้ วิธี class_weight ให้ผลใกล้เคียงกับ SMOTE โดยไม่ต้องสร้างข้อมูลสังเคราะห์ และไม่ทิ้งข้อมูลเหมือนวิธี Undersampling คณะผู้จัดทำจึงเลือกใช้ class_weight กับทุกแบบจำลอง

4.2 ผลการเปรียบเทียบแบบจำลอง

บนชุดทดสอบ Decision Tree ได้ค่า Accuracy 0.795, Recall 0.72 และ F1 0.255 ส่วน Random Forest ได้ค่า Accuracy 0.843, Recall 0.64 และ F1 0.284 อย่างไรก็ตามชุดทดสอบมีผู้ป่วยเพียง 50 ราย ผลลัพธ์จึงมีความแปรปรวนสูง การคัดเลือกแบบจำลอง

จึงอาศัยผลของ Stratified 5-Fold Cross-Validation บนชุดข้อมูลฝึกเป็นหลัก (ค่าเฉลี่ย $\pm$ ส่วนเบี่ยงเบนมาตรฐาน) ดังนี้

- **Logistic Regression:** Recall 0.799 ± 0.070 , F1 0.242 ± 0.024 , PR-AUC 0.225 ± 0.039 และ ROC-AUC 0.854 ± 0.024
- **Decision Tree:** Recall 0.779 ± 0.065 , F1 0.205 ± 0.020 , PR-AUC 0.190 ± 0.029 และ ROC-AUC 0.790 ± 0.015
- **Random Forest:** Recall 0.547 ± 0.048 , F1 0.258 ± 0.019 , PR-AUC 0.201 ± 0.030 และ ROC-AUC 0.831 ± 0.030

ผลดังกล่าวแสดงว่า Logistic Regression ให้ค่า Recall, PR-AUC และ ROC-AUC สูงที่สุดในสามแบบจำลอง ส่วน Random Forest ให้ค่า F1 สูงที่สุดแต่มีค่า Recall ต่ำ เนื่องจากทำนายกลุ่มผู้ป่วยอย่างระมัดระวังมากกว่า และ Decision Tree มีค่า Recall ใกล้เคียงกับ Logistic Regression แต่ค่า PR-AUC และ ROC-AUC ต่ำกว่า

4.3 การวิเคราะห์ Overfitting และการปรับค่าไฮเปอร์พารามิเตอร์

Decision Tree ที่ไม่จำกัดความลึกให้ค่า F1 บนชุดข้อมูลฝึกเท่ากับ 1.00 แต่บนชุดทดสอบเหลือเพียง 0.10 แสดงถึงการเกิด overfitting อย่างชัดเจน เมื่อจำกัด max_depth เท่ากับ 5 ค่า F1 ของทั้งสองชุดมีค่าใกล้เคียงกัน (0.28 และ 0.26) ขณะที่ Random Forest มีผลต่างระหว่างสองชุดเพียง 0.11 เนื่องจากการรวมผลจากต้นไม้หลายต้น (bagging) ช่วยลดความแปรปรวน

ผลการปรับค่าไฮเปอร์พารามิเตอร์ของ Logistic Regression ด้วย GridSearchCV พบว่าชุดค่าที่ได้อันดับหนึ่ง ($C = 0.01$, $L1$; PR-AUC 0.233) กำหนดสัมพันธ์ของ hypertension และ heart_disease เป็นศูนย์ และมีคะแนนต่างจากชุดค่าอื่นน้อยกว่าส่วนเบี่ยงเบนมาตรฐาน (ประมาณ 0.035) คณะผู้จัดทำจึงเลือกชุดค่า $C = 0.1$ กับ $L2$ ซึ่งมีคะแนนอยู่ในช่วงเดียวกันและยังคงใช้ปัจจัยทางการแพทย์ครบถ้วน

4.4 ผลการคัดเลือกคุณลักษณะ

คณะผู้จัดทำทดลองคัดเลือกคุณลักษณะโดยใช้ Logistic Regression และวัดผลด้วย 5-fold Cross-Validation จำนวน 4 ชุด ดังนี้


- **ชุด A ใช้คุณลักษณะทั้งหมด 10 รายการ:** Recall 0.799 ± 0.065 และ PR-AUC 0.226 ± 0.039
- **ชุด B ตัด gender และ Residence_type (8 รายการ):** Recall 0.794 ± 0.057 และ PR-AUC 0.230 ± 0.040
- **ชุด C ตัด ever_married และ work_type เพิ่มจากชุด B (6 รายการ):** Recall 0.799 ± 0.052 และ PR-AUC 0.228 ± 0.037
- **ชุด D ใช้อายุเพียงคุณลักษณะเดียว:** Recall 0.809 ± 0.090 และ PR-AUC 0.166 ± 0.016

ชุด C ใช้คุณลักษณะเพียง 6 รายการ ได้แก่ age, hypertension, heart_disease, avg_glucose_level, bmi และ smoking_status แต่ให้ผลเทียบเท่าชุดที่ใช้คุณลักษณะทั้งหมดภายในช่วงส่วนเบี่ยงเบนมาตรฐาน จึงเลือกชุด C เนื่องจากแบบจำลองมีความ

เรียบง่ายกว่า ปราศจากตัวแปรกวน และทำให้แบบฟอร์มบนเว็บแอปพลิเคชันกระชับขึ้น ส่วนผลของชุด D ยืนยันว่าอายุเพียงลำพังไม่เพียงพอต่อการทำนาย


4.5 ผลของแบบจำลองสุดท้าย

แบบจำลองสุดท้ายคือ **Logistic Regression (C = 0.1, L2, class_weight = balanced)** ที่ใช้คุณลักษณะ 6 รายการ ค่าเกณฑ์ตัดสินที่เลือกจาก Cross-Validation เท่ากับ **0.49** (Recall ใน Cross-Validation เท่ากับ 0.814) ผลบนชุดทดสอบได้ค่า **Recall 0.82** (ระบุผู้ป่วยได้ถูกต้อง 41 จาก 50 ราย) Precision 0.139, F1 0.238, Accuracy 0.743, PR-AUC 0.212 และ ROC-AUC 0.836 ดังแสดงในรูปที่ 3



รูปที่ 3 Confusion Matrix, ROC Curve และ Precision-Recall Curve ของแบบจำลองสุดท้ายบนชุดทดสอบ

ค่าสัมประสิทธิ์ของแบบจำลอง (รูปที่ 4 ก) แสดงว่า อายุ มีอิทธิพลสูงสุด (1.62) รองลงมาคือภาวะความดันโลหิตสูง (0.62) และการไม่มีข้อมูล bmi (0.33) ซึ่งสอดคล้องกับผลการสำรวจข้อมูล ส่วน Learning Curve (รูปที่ 4 ข) แสดงว่าคะแนนของชุดข้อมูลฝึกและชุดตรวจสอบลู่เข้าหากันที่ค่า PR-AUC ประมาณ 0.23 จึงไม่พบ overfitting แต่ประสิทธิภาพถูกจำกัดด้วยปริมาณและคุณลักษณะของข้อมูล



รูปที่ 4 (ก) ค่าสัมประสิทธิ์ของแบบจำลองสุดท้าย และ (ข) Learning Curve ของแบบจำลองสุดท้าย

4.6 เหตุผลในการเลือกแบบจำลองสุดท้าย

- ค่า Recall ใน Cross-Validation สูงที่สุด (0.80) ซึ่งเป็นตัวชี้วัดหลักของงานคัดกรอง ขณะที่ Random Forest มีค่า F1 สูงกว่าเล็กน้อยแต่มีค่า Recall เพียง 0.55
- ค่า PR-AUC และ ROC-AUC สูงที่สุด และมีส่วนเบี่ยงเบนมาตรฐานต่ำ แสดงถึงความเสถียรของแบบจำลอง
- สามารถอธิบายผลได้ ผ่านค่าสัมประสิทธิ์ ซึ่งเหมาะสมกับงานด้านสุขภาพ และให้คะแนนแบบต่อเนื่องที่นำไปแสดงบนเว็บแอปพลิเคชันได้

4.7 ผลการพัฒนาเว็บแอปพลิเคชัน

เว็บแอปพลิเคชัน StrokeCheck (รูปที่ 5) ประกอบด้วยช่องกรอกข้อมูล 6 รายการ ปุ่ม Predict และส่วนแสดงผลซึ่งระบุระดับความเสี่ยง คะแนนความเสี่ยงเทียบกับเกณฑ์ 0.49 บนแถบคะแนน ความหมายของผลลัพธ์ และคำแนะนำ ส่วนประมวลผลตรวจสอบช่วงค่าและค่าเชิงกลุ่มก่อนส่งเข้าแบบจำลอง และรองรับกรณีที่ผู้ใช้ไม่ทราบค่า bmi เนื่องจาก Pipeline จะเติมค่าให้โดยอัตโนมัติ

รูปที่ 5 ผลการทำนายบนเว็บแอปพลิเคชัน (กรณีมีความเสี่ยง คะแนน 0.77)

5. อภิปรายผล (Discussion)

5.1 จุดเด่นของแบบจำลอง

- สามารถระบุผู้ป่วยได้ร้อยละ 82 บนชุดทดสอบ และประมาณร้อยละ 80 ใน Cross-Validation ขณะที่แบบจำลองฐานไม่สามารถระบุผู้ป่วยได้เลย
- ใช้ข้อมูลนำเข้าเพียง 6 รายการซึ่งหาได้ง่าย และสามารถอธิบายอิทธิพลของแต่ละปัจจัยได้
- การใช้ Pipeline ป้องกันการรั่วไหลของข้อมูล และทำให้เว็บแอปพลิเคชันรับข้อมูลดิบ รวมถึงกรณีที่ไม่มีค่า bmi ได้โดยตรง

5.2 จุดอ่อนและข้อจำกัด

- ค่า Precision ต่ำ (0.14) กล่าวคือ ในผู้ที่ได้รับการแจ้งเตือนประมาณ 7 ราย จะเป็นผู้ป่วยจริงเพียง 1 ราย ระบบจึงเหมาะสำหรับการคัดกรองเบื้องต้นเท่านั้น
- คะแนนจากแบบจำลองที่ใช้ class weight ไม่ใช่ค่าความน่าจะเป็นที่แท้จริง เว็บแอปพลิเคชันจึงใช้คำว่า "คะแนนความเสี่ยง" แทน "โอกาสการเป็นโรค"
- แบบจำลองยังไม่สามารถระบุผู้ป่วยได้ประมาณ 1 ใน 5 ราย และรองรับเฉพาะเพศชายและหญิง เนื่องจากข้อมูลเพศอื่นมีไม่เพียงพอ

5.3 ปัญหาที่พบระหว่างการดำเนินงาน

- ความไม่สมดุลของข้อมูลทำให้ Accuracy ให้ภาพที่คลาดเคลื่อน และชุดทดสอบมีผู้ป่วยเพียง 50 ราย ผลจึงมีความแปรปรวนสูง คณะผู้จัดทำแก้ไขโดยใช้ Cross-Validation เป็นหลักในการคัดเลือกแบบจำลอง
- ค่า bmi สูญหายแบบไม่สุ่ม และ smoking_status มีค่า Unknown จำนวนมาก จึงต้องเลือกวิธีการจัดการที่ไม่ทำให้สูญเสียข้อมูล

- ผลอันดับหนึ่งจาก GridSearchCV ไม่ใช่ทางเลือกที่เหมาะสมที่สุดในทางปฏิบัติเสมอไป จำเป็นต้องพิจารณาส่วนเบี่ยงเบนมาตรฐานและความสมเหตุสมผลทางการแพทย์ร่วมด้วย
- ความสัมพันธ์บางประการเกิดจากตัวแปรกวน เช่น ever_married และ work_type ที่สัมพันธ์กับโรคผ่านตัวแปรอายุ ซึ่งมีใช้ความสัมพันธ์เชิงเหตุและผล

5.4 แนวทางการพัฒนาในอนาคต

- เพิ่มปริมาณข้อมูลและคุณลักษณะทางคลินิก เช่น ค่าความดันโลหิต ระดับคอเลสเตอรอล และประวัติครอบครัว เนื่องจาก Learning Curve ชี้ว่าข้อจำกัดหลักอยู่ที่ข้อมูล
- ปรับเทียบความน่าจะเป็น (probability calibration) เพื่อให้คะแนนสามารถตีความเป็นโอกาสได้ และแสดงปัจจัยที่ส่งผลต่อคะแนนของผู้ใช้แต่ละรายบนเว็บแอปพลิเคชัน
- ทดลองแบบจำลองกลุ่ม boosting และทดสอบกับข้อมูลจากแหล่งอื่น (external validation) ก่อนนำไปใช้งานจริง

6. เอกสารอ้างอิง (References)

- [1] V. L. Feigin et al., "World Stroke Organization: Global Stroke Fact Sheet 2025," International Journal of Stroke, vol. 20, no. 2, pp. 132–144, 2025, doi: 10.1177/17474930241308142.
- [2] fedesoriano, "Stroke Prediction Dataset," Kaggle. [Online]. Available: <https://www.kaggle.com/datasets/fedesoriano/stroke-prediction-dataset> (สืบค้นเมื่อ).
- [3] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," Journal of Machine Learning Research, vol. 12, pp. 2825–2830, 2011.
- [4] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, "SMOTE: Synthetic Minority Over-sampling Technique," Journal of Artificial Intelligence Research, vol. 16, pp. 321–357, 2002.
- [5] G. Lemaître, F. Nogueira, and C. K. Aridas, "Imbalanced-learn: A Python Toolbox to Tackle the Curse of Imbalanced Datasets in Machine Learning," Journal of Machine Learning Research, vol. 18, no. 17, pp. 1–5, 2017.
- [6] T. Saito and M. Rehmsmeier, "The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets," PLOS ONE, vol. 10, no. 3, e0118432, 2015.
- [7] Pallets, "Flask Documentation." [Online]. Available: <https://flask.palletsprojects.com/>
- [8] เอกสารประกอบการสอนรายวิชา 344-362 Machine Learning หัวข้อ Data, KNN/Decision Tree/Logistic Regression, Evaluation and Selection และ Imbalanced Data/Overfitting/Ensemble.